

Analisis Prediktif Klaim Asuransi AXA Mandiri Menggunakan Gradient Boosting dan Optimasi Algoritma Evolusioner



BlackAjip

- 1. Muhammad Luthfi Aziz S.**
- 2. Danish Rahadian Mirza E.**
- 3. Athallah Azhar Aulia Hadi**

**DATA SCIENCE COMPETITION
MATHEMATICAL CHALLENGE FESTIVAL
INSTITUT TEKNOLOGI BANDUNG
2026**

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim : BlackAjip
Nama Ketua Tim : Muhammad Luthfi Aziz Sunarya
Nama Anggota Tim 1 : Danish Rahadian Mirza Effendi
Nama Anggota Tim 2 : Athallah Azhar Aulia Hadi

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan [Nama Perlombaan yang Diikuti] MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model: Gemini

Pengembang Model: Google

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

1. Penulisan laporan agar sesuai dengan puebi dan menggunakan bahasa indonesia yang baik.
2. Pembuatan code untuk mempercepat eksplorasi terhadap dataset.

Kami menyatakan bahwa seluruh keluaran model model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi dari perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Jatinangor, 10 Maret 2026

Yang menyatakan,



Muhammad Luthfi Aziz Sunarya

DAFTAR GAMBAR

Gambar 3.1 Perbandingan Signal to Ratio Target Feature Group By Day, Week, dan Month

Gambar 3.2 Perbandingan Coefficient of Variation Antar Target

Gambar 3.3 Outlier Nominal Klaim yang Disetujui

Gambar 3.4 Hasil Capping Outlier Nominal Klaim yang Disetujui

Gambar 3.5 Bar Chart Rata-Rata Claim Frequency Group By Day

Gambar 3.6 Distribusi Domisili

Gambar 3.7 Perbandingan Curah Hujan Maksimal Jakarta dengan Frekuensi Klaim

Gambar 3.8 Regression Line Time Index Square

Gambar 3.9 Visualisasi Simetri Month Cos

Gambar 3.10 Validasi Keserupaan Claim Severity By Month Cos

Gambar 3.11 Grafik CCF Lag Predictor Total Klaim Terhadap Frekuensi Klaim

Gambar 3.12 Grafik CCF Lag Predictor Total Klaim Terhadap Frekuensi Klaim

Gambar 3.13 Grafik CCF Lag Predictor Total Klaim Terhadap Claim Severity

Gambar 3.14 Feature Importance Untuk Claim Frequency

Gambar 3.15 Feature Importance Untuk Claim Severity

Gambar 3.16 Grafik YoY Hasil Prediksi Total Klaim

Gambar 3.17 Grafik YoY Hasil Prediksi Claim Frequency

Gambar 3.18 Grafik YoY Hasil Prediksi Claim Severity

DAFTAR ISI

BAB I PENDAHULUAN

A. Latar Belakang.....	
B. Rumusan Masalah.....	
C. Tujuan.....	
D. Manfaat.....	

BAB II TINJAUAN PUSTAKA & METODOLOGI

A. Penjelasan Data.....	
B. Persiapan Data.....	
C. Pemilihan Model.....	
D. Feature Engineering.....	
E. Feature Selection.....	
F. Recursive Forecast.....	
G. Hyperparameter Tuning.....	

BAB III HASIL DAN PEMBAHASAN

A. Exploratory Data Analysis.....	
B. Machine Learning Training.....	
C. Hasil Prediksi.....	

BAB IV PENUTUPAN

A. Kesimpulan dan Saran.....	
B. Daftar Pustaka.....	

INTISARI — Lonjakan beban klaim asuransi kesehatan sebesar 25,5 persen pada pertengahan tahun 2025 mengancam stabilitas finansial perusahaan dan keterjangkauan harga premi bagi masyarakat. Penelitian ini bertujuan untuk mengidentifikasi faktor determinan yang memengaruhi frekuensi dan severitas klaim, serta membangun model prediksi pembelajaran mesin yang akurat guna memproyeksikan tren klaim di masa depan. Pemodelan dilakukan menggunakan data historis polis dan klaim periode Januari 2024 hingga Juli 2025. Pendekatan dekomposisi frekuensi dan severitas diimplementasikan menggunakan keluarga algoritma Gradient Boosted Trees, dengan algoritma CatBoost sebagai model utama. Prapemrosesan data mencakup penanganan nilai ekstrem menggunakan metode pemotongan (capping) pada batas kuantil 0,97. Tahap optimasi model dilakukan secara berlapis melalui seleksi fitur berbasis Evolutionary Computation untuk mereduksi dimensi dan meminimalkan gangguan, serta penyetelan hyperparameter secara otomatis menggunakan algoritma genetika. Proyeksi klaim dieksekusi menggunakan metode peramalan rekursif untuk horizon lima bulan ke depan. Hasil penelitian menyimpulkan bahwa frekuensi klaim secara dominan dipengaruhi oleh tren historis lag total klaim dan jumlah hari kerja, sedangkan severitas klaim sangat responsif terhadap intensitas curah hujan ekstrem dan siklus kalender tahunan. Sinergi dari tahapan optimasi memungkinkan CatBoost menangkap hubungan non-linear yang kompleks secara efektif, menghasilkan model yang stabil dan tangguh dengan tingkat galat Public Score mencapai 1,06 persen. Model terbukti berhasil mempertahankan pola musiman jangka panjang secara konsisten, meskipun memiliki limitasi berupa penghalusan (smoothing) terhadap fluktuasi yang bersifat ekstrem. Sebagai implikasi manajerial, perusahaan direkomendasikan untuk mengalokasikan cadangan kontingensi tambahan serta memantau pembaruan data eksogen secara berkala guna mengantisipasi anomali klaim dan menjaga stabilitas finansial.

KATA KUNCI — Asuransi Kesehatan; Prediksi Klaim; Pembelajaran Mesin; Gradient Boosted Trees; Komputasi Evolusioner; Algoritma Genetika; Peramalan Rekursif.

I. PENDAHULUAN

A. LATAR BELAKANG

Produk asuransi kesehatan individu memiliki peran krusial sebagai instrumen mitigasi risiko finansial terhadap kejadian tidak terduga, seperti penyakit atau kecelakaan. Perlindungan ini memastikan bahwa masyarakat terhindar dari beban biaya medis yang tinggi, yang berpotensi merusak perencanaan keuangan pribadi. Oleh karena itu, menjaga stabilitas dan keterjangkauan produk asuransi kesehatan merupakan prioritas utama bagi penyedia layanan asuransi.

Namun, industri asuransi kesehatan saat ini sedang dihadapkan pada tantangan operasional yang signifikan. Berdasarkan pencatatan terbaru, terjadi lonjakan beban klaim asuransi kesehatan individu sebesar 25,5 persen pada periode Januari hingga Juni 2025, apabila dibandingkan dengan periode yang sama pada tahun 2024. Peningkatan drastis ini berdampak langsung pada keseimbangan finansial perusahaan, yang pada akhirnya memicu penyesuaian tarif premi. Jika tren ini dibiarkan tanpa intervensi, harga premi produk asuransi kesehatan individu berisiko menjadi terlalu mahal dan tidak lagi terjangkau oleh masyarakat luas.

Untuk mencegah eskalasi masalah tersebut, diperlukan sebuah intervensi strategis yang didasari oleh analisis data yang kuat. Perusahaan memerlukan pemahaman yang komprehensif terkait faktor-faktor apa saja yang paling memengaruhi tingkat keparahan (severitas) maupun tingkat kejadian (frekuensi) dari sebuah klaim. Dengan mengetahui akar permasalahan dari data historis, penyedia asuransi dapat merancang inisiatif mitigasi yang efektif, seperti penyempurnaan proses seleksi risiko, pelaksanaan program pencegahan, hingga kampanye deteksi dini kesehatan bagi nasabahnya.

Menjawab urgensi tersebut, laporan ini disusun untuk menguraikan langkah-langkah analitis dalam meretas pola klaim asuransi kesehatan. Analisis difokuskan pada tahap pembersihan data, eksplorasi variabel penentu, hingga perancangan model prediksi. Laporan ini menerapkan pendekatan machine learning yang dipadukan dengan teknik optimasi algoritma evolusioner untuk meramalkan tren frekuensi, tren severitas, dan total nominal klaim di masa depan. Pemodelan ini juga melibatkan proses evaluasi kinerja pada berbagai algoritma guna memastikan keandalan hasil prediksi, sehingga dapat dijadikan landasan pengambilan keputusan yang akurat demi menjaga stabilitas harga premi.

B. RUMUSAN MASALAH

1. Faktor-faktor eksternal maupun historis apa saja yang paling signifikan dalam memengaruhi tingkat kejadian (frekuensi) dan tingkat keparahan (severitas) klaim asuransi kesehatan individu?
2. Bagaimana membangun dan mengoptimalkan model machine learning yang mampu memprediksi tren masa depan terkait frekuensi, severitas, dan proyeksi total nominal klaim secara akurat?
3. Bagaimana hasil evaluasi dan perbandingan performa antara model machine learning yang dikembangkan dalam menjaga ketahanan (robustness) prediksi terhadap fluktuasi data klaim di masa depan?

C. TUJUAN

1. Membersihkan dan mengeksplorasi data historis klaim asuransi kesehatan.

2. Mengidentifikasi faktor utama penentu tingkat kejadian (frekuensi) dan keparahan (severitas) klaim.
3. Membangun model machine learning untuk memprediksi tren frekuensi, severitas, dan total nominal klaim.
4. Mengevaluasi performa model machine learning untuk memastikan akurasi dan ketahanan prediksi.

D. MANFAAT

1. Membantu perusahaan menyempurnakan panduan manajemen risiko secara presisi.
2. Mendukung aktuaria dalam pencadangan dana yang akurat guna mencegah lonjakan harga premi produk.
3. Menjadi landasan perancangan program deteksi dini kesehatan untuk menekan angka keparahan klaim.
4. Memberikan sistem peramalan yang andal sebagai dasar penentuan strategi bisnis bagi manajemen.

II. TINJAUAN PUSTAKA & METODOLOGI

A. PENJELASAN DATA

Penelitian ini menggunakan dua dataset historis asuransi kesehatan periode 1 Januari 2024 hingga 31 Juli 2025, yang direlasikan menggunakan kunci Nomor Polis:

1. Data Polis (4.096 baris, 6 atribut) berfungsi sebagai tabel dimensi yang merepresentasikan profil risiko nasabah. Atributnya mencakup identitas demografis (Gender, Tanggal Lahir, Domisili) serta spesifikasi produk asuransi (Plan Code, Tanggal Efektif Polis).
2. Data Klaim (5.781 baris, 13 atribut) dengan periode 1 Januari 2024 s/d 31 Desember 2025 berfungsi sebagai tabel fakta yang merepresentasikan kejadian historis klaim. Atributnya mencakup rincian medis (ICD Diagnosis, *Inpatient/Outpatient*, Tanggal Masuk/Keluar RS), operasional (Metode Pembayaran, Status Klaim, Lokasi RS), dan finansial (Nominal Tagihan RS dan Nominal Klaim Disetujui).

Target pemodelan, yaitu trend frekuensi, trend severitas, dan tren total claim. untuk periode Agustus hingga Desember 2025.

B. PERSIAPAN DATA

Sebelum tahap pemilihan model, dilakukan persiapan dataset untuk kedua sumber data utama. Data di dunia nyata seringkali mengandung kesalahan, ketidakkonsistenan, nilai yang hilang, dan nilai

ekstrem, sehingga pembersihan data menjadi langkah krusial untuk memastikan performa dan keandalan model machine learning [1]. Untuk memastikan kualitas dan struktur data yang optimal, tahap persiapan dilakukan dengan urutan sebagai berikut:

a. Transformasi Data (Waktu dan ICD)

Tahap pertama adalah melakukan penyesuaian format pada fitur waktu agar memiliki standar yang seragam untuk analisis runtun waktu. Selain itu, dilakukan perbaikan konsistensi penulisan pada fitur diagnosis ICD. Ditemukan adanya ketidakkonsistenan penggunaan huruf kecil pada kode diagnosis, sehingga seluruh data ICD diseragamkan untuk mencegah duplikasi kategori dan menjaga integritas data [1].

b. Imputasi Data Kosong

Setelah format data ditransformasi, langkah selanjutnya adalah menangani data yang hilang atau kosong. Proses imputasi diterapkan pada fitur-fitur yang tidak lengkap untuk memastikan seluruh baris data memiliki informasi yang utuh dan siap untuk digabungkan, yang mana merupakan praktik terbaik dalam prapemrosesan data [1].

c. Integrasi Data

Dataset polis dan dataset klaim yang telah dibersihkan kemudian digabungkan menjadi satu himpunan data utama terpadu. Integrasi ini penting untuk menghubungkan setiap riwayat kejadian klaim dengan profil detail pemegang polis yang bersangkutan.

d. Penanganan Nilai Ekstrem (Capping)

Dalam tahapan pra-pemrosesan data, digunakan metode capping untuk menangani nilai ekstrem (outlier) pada variabel nominal klaim. Penentuan ambang batas dilakukan dengan menggunakan pendekatan statistik berbasis kuantil, di mana batas atas ditetapkan pada persentil ke-97 (Q0,97). Pemilihan batas ini didasarkan pada karakteristik data klaim asuransi yang sering kali memiliki ekor distribusi yang sangat panjang (heavy-tailed), di mana nilai-nilai di atas batas tersebut cenderung bersifat fluktuatif, acak, dan tidak membentuk pola historis yang konsisten (unlearnable pattern).

Secara teknis, penggunaan capping bertujuan untuk memitigasi risiko over-prediction sistematis selama proses peramalan rekursif. Mengingat evaluasi model dilakukan menggunakan metrik Mean Absolute Percentage Error (MAPE) yang memiliki sensitivitas tinggi terhadap deviasi ekstrem, pembatasan nilai pada ambang kuantil tertentu menjadi krusial. Strategi ini memastikan bahwa algoritma pembelajaran mesin tetap fokus pada tren fundamental yang

merepresentasikan kondisi operasional normal perusahaan tanpa terdistorsi oleh anomali biaya yang sangat besar.

e. Agregasi Data Bulanan (Grouping)

Data yang telah terintegrasi dan dibatasi nilai ekstremnya kemudian diubah bentuknya menjadi pivot bulanan. Pengelompokan ini didasarkan pada tanggal pasien masuk rumah sakit. Pada tahap ini, dilakukan perhitungan untuk fitur target, yaitu total klaim, frekuensi klaim, dan severitas (diformulasikan dari total klaim dibagi dengan frekuensi klaim). Selain itu, dilakukan juga pengelompokan terhadap fitur eksogen untuk melihat komposisi bulanan, yang meliputi jenis kelamin, lokasi rumah sakit, diagnosis ICD, kode program asuransi, metode klaim, domisili bertanggung, serta kategori perawatan.

C. PEMILIHAN MODEL

Dalam penelitian ini, pendekatan pembelajaran mesin yang dipilih sebagai model prediktif utama adalah kerangka kerja berbasis Gradient Boosted Trees (GBT). Keputusan ini didasarkan pada tinjauan literatur mengenai keunggulan empiris keluarga algoritma GBT pada data tabular, yang kemudian dieksplorasi lebih spesifik melalui tiga algoritma mutakhir: XGBoost, LightGBM (LGBM), dan CatBoost. Pemilihan pendekatan ini sangat relevan dengan karakteristik dataset klaim asuransi kesehatan yang bersifat heterogen dan menyusut menjadi sampel yang sangat terbatas, yaitu hanya 19 titik data pengamatan setelah proses agregasi temporal. Berikut adalah landasan utama pemilihan model tersebut dari perspektif umum hingga spesifikasi algoritmanya:

a. Kemampuan Menangkap Pola Kompleks dan Heterogen

Keluarga algoritma GBT memiliki kemampuan yang luar biasa dalam menangkap interaksi antarfitur dan memodelkan pola non-linear [2]. Dalam konteks klaim asuransi, model dituntut untuk memahami interaksi rumit antara faktor eksogen, seperti dinamika cuaca dan kalender, dengan rekam jejak historis klaim tanpa bergantung pada asumsi linearitas yang kaku. Terdapat aturan umum bahwa algoritma Jaringan Saraf Tiruan (Neural Networks) lebih wajib dialokasikan untuk data spasial atau audio, sedangkan GBT jauh lebih unggul dan tangguh untuk data kuantitatif tabular [2]. Dengan hanya 19 sampel, penggunaan Jaringan Saraf Tiruan berisiko sangat tinggi mengalami kegagalan pembelajaran (overfitting).

b. Kesesuaian dengan Tipe Data dan Mitigasi Overfitting pada Sampel Terbatas

Dataset klaim asuransi kesehatan merupakan data kuantitatif dan kategorikal tabular yang menyusut menjadi runtun waktu berskala kecil setelah agregasi. Terdapat aturan umum bahwa algoritma Jaringan Saraf Tiruan (Neural Networks) lebih wajib dialokasikan untuk data spasial atau audio, sedangkan GBT lebih unggul untuk data tabular [2]. Dengan hanya 19 sampel, penggunaan Jaringan Saraf Tiruan akan mengakibatkan kegagalan pembelajaran (overfitting). CatBoost mengatasi hal ini melalui teknik ordered boosting, sebuah alternatif berbasis permutasi yang mencegah bias prediksi dan kebocoran target (target leakage) [3]. Selain itu XGBoost menawarkan optimasi sistem yang terukur dan efisien. Algoritma ini secara inovatif menerapkan fungsi objektif yang diregularisasi (*regularized learning objective*) untuk menghaluskan bobot akhir dan mencegah *overfitting*, sebuah mekanisme yang sangat vital ketika menangani dataset terbatas [11]. Selain itu, XGBoost mengimplementasikan algoritma *sparsity-aware* untuk menangani data yang kosong atau jarang secara otomatis, serta menggunakan *weighted quantile sketch* untuk menemukan titik potong fitur secara presisi [11].

c. Pemrosesan Fitur Kategorikal dan Ketangguhan Model

Dataset ini kaya akan fitur kategorikal dengan kardinalitas tinggi seperti kode diagnosis ICD dan lokasi rumah sakit. CatBoost menerapkan algoritma pemrosesan fitur kategorikal inovatif yang mengubah kategori menjadi statistik numerik tanpa menyebabkan overfitting [3]. Selain itu, penggunaan oblivious trees atau pohon simetris sebagai prediktor dasar berfungsi sebagai skema regularisasi alami untuk menstabilkan variansi model [3]. Hal ini menjadikan CatBoost lebih lugas dan mudah untuk diregularisasi dibandingkan model algoritma lainnya dalam menangani nilai ekstrem pada biaya perawatan medis [2].

d. Efisiensi Pelatihan untuk Peramalan Rekursif

Meskipun GBT dan Jaringan Saraf Tiruan mampu memodelkan non-linearitas, GBT menawarkan proses komputasi yang umumnya lebih cepat dan lebih mudah untuk dilatih [2]. Penggunaan oblivious trees juga mempercepat waktu eksekusi prediksi secara signifikan. Efisiensi ini menjadi sangat krusial karena penelitian ini menggunakan metode

peramalan rekursif, di mana model harus terus memperbarui langkah prediksinya pada setiap iterasi bulan secara berurutan agar tetap efisien dan tahan terhadap gangguan (noise) pada data [3]. LightGBM meruakan salah satu algoritma GBT dengan efisiensi tingkat tinggi melalui algoritma berbasis histogram [10]. Algoritma ini mengandalkan dua teknik baru, yakni *Gradient-based One-Side Sampling* (GOSS) yang mempertahankan instans data dengan gradien besar untuk estimasi *information gain* yang akurat, serta *Exclusive Feature Bundling* (EFB) yang secara efektif menggabungkan fitur-fitur eksklusif guna mereduksi dimensi data [10]. Efisiensi algoritmik ini memastikan proses pelatihan berjalan sangat cepat tanpa mengorbankan tingkat akurasi.

D. FEATURE ENGINEERING

Proses feature engineering dalam time-series forecasting memiliki tingkat kompleksitas yang berbeda dibandingkan dengan bidang machine learning lainnya seperti klasifikasi citra atau teks. Pada data runtun waktu, setiap observasi memiliki urutan dan struktur bawaan (inherent order and structure) yang sering kali dikarakterisasi melalui berbagai ukuran rolling measures dari variance dan central tendency [4]. Selain itu, karena belum tersedianya pretrained models universal untuk time-series seperti halnya dalam bidang audio atau citra, setiap permasalahan memerlukan arsitektur input yang unik [4].

Oleh karena itu, penelitian ini merancang koleksi fitur yang luas untuk digunakan sebagai input bagi model Gradient Boosted Trees (GBT). Seluruh fitur yang telah direkayasa dikelompokkan ke dalam kategori utama dalam tabel berikut:

Kategori	Nama Fitur	Deskripsi dan Tujuan
Temporal and Calendar Features	Month_Num, month_sin, month_cos, Quarter, Is_Year_End, Days_in_Month	Menangkap pola musiman (seasonality) dan struktur unik dari input waktu yang tidak dapat disediakan oleh model standar [4].
	, Public_Holidays, Working_Days, Time_Index, Time_Index_Squared	Penggunaan transformasi siklikal (sin/cos) memastikan model memahami kedekatan temporal antar bulan.

Historical Features (Lags)	Lag_1, Lag_2, Lag_3, Lag_4 (pada variabel Freq, Sev, dan Total)	Mengambil informasi dari urutan observasi masa lalu untuk menangkap dependensi temporal yang menjadi ciri khas data runtun waktu [2][4].
Exogenous Weather Features	Total_Rainfall, Avg_Daily_Rainfall, Max_Daily_Rainfall, Rainy_Days_Count, Extreme_Rain_Days (wilayah Jakarta dan Surabaya)	Mengintegrasikan input eksternal yang relevan secara spesifik dengan domain asuransi kesehatan (penyakit musiman) untuk meningkatkan akurasi prediksi [2].
Rolling Statistics	RM_2, RM_3, RM_4 (Rolling Mean), RStd_2, RStd_3, RStd_4 (Rolling Standard Deviation)	Mencirikan struktur data melalui rolling measures dari central tendency dan variance untuk menghaluskan noise serta menangkap pergeseran distribusi data [4].
Differentiation and Momentum	Diff_1 (Total, Freq, Sev), Lag_1_Diff_1_Freq, Acc_Freq, Momentum_2_Freq, Growth_Rate_Freq	Mengidentifikasi kecepatan perubahan (momentum) dan akselerasi tren guna menangkap dinamika non-linear dalam data tabular.
Technical Indicators and Interactions	Z_Score_Freq, Min_3_Freq, Max_3_Freq, Stoch_K_Freq, MACD_Freq, Rain_x_LagFreq (Jkt, Sby)	Menangani data yang mencakup beberapa skala besaran melalui normalisasi (Z-Score) serta menangkap interaksi fitur kompleks antara kondisi cuaca dengan volume klaim historis [4].

Pengumpulan data eksternal yang mencakup metrik intensitas curah hujan untuk wilayah Jakarta dan Surabaya diperoleh melalui akses publik pada portal web weather-and-climate.com. Metode akuisisi data dilakukan menggunakan teknik web scraping otomatis berbasis bahasa pemrograman Python, dengan memanfaatkan pustaka Selenium WebDriver untuk melakukan simulasi interaksi antarmuka kalender secara dinamis (seperti pemilihan tahun dan bulan dari menu dropdown) dan pustaka

BeautifulSoup untuk mengekstraksi struktur dokumen HTML. Proses scraping ini dirancang secara sistematis dengan logika validasi jumlah hari per bulan untuk mengekstraksi atribut tanggal, nilai curah hujan harian (dalam milimeter), serta kategori intensitas hujan, yang kemudian dikompilasi menjadi format Comma Separated Values (CSV). Metode otomatisasi ini memastikan perolehan data sekunder yang relevan, terstruktur, dan selaras dengan rentang waktu observasi klaim asuransi guna mendukung analisis faktor eksogen pada model prediktif.

E. FEATURE SELECTION

Seleksi fitur (*Feature Selection*) merupakan teknik prapemrosesan yang sangat krusial dalam bidang pembelajaran mesin untuk mengidentifikasi subset variabel yang paling prediktif [5]. Masalah seleksi fitur dikategorikan sebagai optimasi kombinatorial yang memiliki ruang pencarian sangat luas sebesar 2^n kemungkinan kombinasi fitur [5]. *Evolutionary Computation* (EC) digunakan dalam penelitian ini karena kemampuannya dalam melakukan pencarian global yang superior untuk menemukan solusi optimal di tengah kompleksitas tersebut [5]. Mengingat dataset ini hanya berjumlah 19 baris, penggunaan EC menjadi instrumen utama untuk mengeliminasi variabel pengganggu (*noise*) guna mencegah terjadinya *overfitting*.

Proses EC dimulai dengan inisialisasi populasi sebanyak 100 individu, di mana setiap individu merepresentasikan satu kombinasi subset fitur unik. Setiap individu dievaluasi menggunakan fungsi fitness (*fitness function*) yang bertujuan untuk meminimalkan nilai *Mean Absolute Percentage Error* (MAPE) [5]. Mekanisme evolusi dilakukan melalui operator seleksi untuk mempertahankan kombinasi fitur terbaik, serta operator persilangan (*crossover*) dan mutasi untuk mengeksplorasi variasi fitur baru [5]. Operator mutasi berperan penting dalam menjaga keberagaman populasi agar proses pencarian tidak terjebak dalam kondisi *local optima* [5]. Seluruh tahapan evolusi ini dijalankan secara iteratif selama 20 generasi hingga mencapai konvergensi pada subset fitur yang paling stabil.

F. RECURSIVE FORECAST

Penelitian ini mengimplementasikan *Iterative Multi-Step Forecasting* (peramalan rekursif) untuk horizon lima bulan ke depan. Pendekatan ini memprediksi satu langkah ke depan (t), yang hasilnya secara sekuensial digunakan sebagai fitur input untuk meramalkan langkah berikutnya [5]. Untuk

memperkaya sinyal prediktif, ruang fitur diinjeksi dengan data eksogen spasio-temporal (fitur kalender dan intensitas curah hujan).

Metodologi dieksekusi melalui skema dua fase. Fase pertama adalah *Out-of-Sample Holdout Validation*, di mana 5 bulan terakhir diisolasi sebagai *baseline* untuk menguji stabilitas model. Fase kedua adalah pelatihan final (*Full Dataset Training*), di mana algoritma *Model* dilatih ulang menggunakan 100% observasi historis guna menyerap tren makro paling mutakhir.

Selama fase *forecast*, variabel eksogen deterministik diproyeksikan secara absolut, sedangkan fitur endogen dinamis (seperti *Lag* dan *Rolling Mean*) direkalkulasi secara iteratif menggunakan estimasi langkah sebelumnya ($\hat{y}_{T-h+1}$).

Batasan inheren dari metode rekursif ini adalah *error accumulation*, di mana variansi prediktif awal teramplifikasi secara eksponensial seiring bertambahnya horizon waktu [7]. Sebagai mitigasi komputasional, pemodelan menerapkan batasan asimtotik (*clipping* batas bawah) untuk mencegah estimasi negatif atau nol mutlak yang dapat mendistorsi rekalkulasi fitur pada iterasi lanjutan.

G. HYPERPARAMETER TUNING

Optimasi hyperparameter memiliki peran sentral dalam menentukan performa akhir dari sebuah model pembelajaran mesin secara signifikan [6]. Pendekatan konvensional seperti pencarian manual, grid search, atau random search sering kali menemui kendala efisiensi saat harus menangani ruang pencarian yang bersifat kompleks dan berdimensi tinggi [6]. Sebagai alternatif yang lebih cerdas, penelitian ini menerapkan algoritma genetika (*Genetic Algorithm*) untuk melakukan pencarian parameter secara otomatis dan terarah [6]. Penggunaan teknik ini menjadi krusial dalam menangani model gradient boosting seperti CatBoost yang memiliki ruang parameter yang luas dan sensitif terhadap perubahan kecil.

Algoritma genetika beroperasi dengan mensimulasikan mekanisme evolusi alamiah melalui operator seleksi, persilangan (*crossover*), dan mutasi [6]. Penggunaan pustaka pendukung seperti *mloptimizer* memungkinkan integrasi proses evolusi ini untuk mencari konfigurasi terbaik pada model secara paralel dan efisien [6]. Melalui pendekatan


berbasis populasi ini, eksplorasi terhadap ruang parameter yang luas dapat dilakukan dengan lebih mendalam dibandingkan metode pencarian sekuensial yang memakan waktu lama [6]. Dengan mendukung eksekusi paralel, algoritma ini mampu memproses berbagai kombinasi individu dalam populasi secara serentak untuk mempercepat penemuan solusi optimal [6].

Secara teknis, proses optimasi dalam penelitian ini dijalankan dengan inisialisasi 100 individu dalam populasi selama 20 generasi guna mencapai titik konvergensi solusi yang paling stabil. Setiap individu dievaluasi menggunakan fungsi fitness yang berfokus pada minimalisasi Mean Absolute Percentage Error (MAPE) untuk menjamin akurasi prediksi klaim asuransi kesehatan yang maksimal.

III. HASIL DAN PEMBAHASAN

A. EXPLORATORY DATA ANALYSIS


1) AGREGASI TEMPORAL DAN DEKOMPOSISI TARGET



Gambar 3.1 Perbandingan Signal To Ratio Target Feature Group By Day, Week & Month

Observasi terhadap resolusi temporal membuktikan bahwa agregasi bulanan merupakan prasyarat utama untuk menghasilkan sinyal data yang stabil sebagai basis pelatihan model. Sebagaimana diperlihatkan pada lampiran gambar ke 3.1, analisis Signal-to-Noise Ratio (SNR) menunjukkan peningkatan kualitas sinyal secara signifikan saat data diagregasi dari skala harian ke bulanan. Pada skala harian dan mingguan, nilai SNR berada pada titik terendah karena fluktuasi didominasi oleh noise stokastik dan efek kalender operasional yang berisiko tinggi memicu overfitting. Sebaliknya, agregasi bulanan secara efektif mengekstraksi tren fundamental yang lebih stasioner dengan rasio sinyal terhadap gangguan yang jauh lebih tinggi. Hal ini menyediakan matriks fitur historis yang stabil bagi algoritma


Gradient Boosting untuk menangkap pola jangka panjang secara akurat.



Gambar 3.2 Perbandingan Coefisien Variation Antar Target


Justifikasi matematis untuk menggunakan model dekomposisi alih-alih estimasi langsung pada Total Claim juga diperkuat oleh hasil observasi pada Gambar 3.2 dan 3.1. Terlihat pada Gambar 3.2 bahwa Total Claim memiliki tingkat variabilitas tertinggi dengan Koefisien Variasi (CV) mencapai 10,77 persen, sementara Gambar 3.1 mengonfirmasi bahwa komponen pembentuknya, yaitu Claim Frequency dan Claim Severity, memiliki stabilitas sinyal yang lebih baik saat diproses secara terpisah. Karena Total Claim bertindak sebagai akumulator variansi dari dua proses stokastik yang berbeda, prediksi langsung pada nominal total akan mendistorsi model dengan memaksanya meregresi dua dimensi independen secara simultan. Melalui pendekatan frequency-severity model, model dapat mengisolasi fungsi musiman populasi dari dinamika biaya medis secara independen, yang terbukti secara empiris mampu mereduksi error variance dibandingkan arsitektur target tunggal.

2) KARAKTERISTIK OUTLIER



Gambar 3.3 Outlier Nominal Claim Yang Disetujui


Berdasarkan hasil perhitungan pada dataset riil, diperoleh nilai ambang batas pemotongan (capping) sebesar Rp 336.573.031,66. Audit terhadap distribusi data menunjukkan bahwa dari total 4.627 baris transaksi, terdapat 139 baris (3,00%) yang teridentifikasi melampaui batas tersebut dan dikenakan prosedur capping. Visualisasi pada Gambar 3.3 memperlihatkan sebaran data riil sebelum penanganan, di mana titik-titik pencilan tersebar jauh di atas garis tren biaya umum.



Gambar 3.4 Hasil Capping Outlier Nominal Claim Yang Disetujui


Implementasi prosedur tersebut ditunjukkan pada Gambar 3.4, dimana seluruh nilai ekstrem telah disesuaikan tepat pada batas nominal kuantil 0,97. Pengurangan variansi ekstrem ini terbukti meningkatkan stabilitas model secara signifikan. Hasil evaluasi menunjukkan bahwa dengan menormalkan 3% data tertinggi, model mampu memberikan estimasi biaya yang lebih objektif dan tahan terhadap gangguan (noise), sehingga menjamin kualitas proyeksi total klaim pada periode target tetap berada dalam rentang kesalahan yang dapat diterima secara bisnis.

3) PENGARUH FITUR EKSOGEN



Gambar 3.5 Barchart Rata-Rata Claim Frequency Group By Day


Pada lampir Gambar 3.5 terlihat bahwa claim frequency di hari Sabtu dan Minggu lebih sedikit dari hari-hari lainnya, Karena datanya diambil dengan Group By tanggal masuk RS maka ini memberi insight bahwa jumlah pasien lebih banyak masuk RS di working days dibanding weekend days ini melatarbelakangi feature Working_days dalam 1 bulan untuk memprediksi Claim Frequency.




Gambar 3.6 Distribusi Domisili

Sebelum melakukan analisis mendalam terhadap pengaruh cuaca, peneliti terlebih dahulu melakukan pemetaan terhadap persebaran geografis pasien guna memastikan relevansi data meteorologi yang digunakan. Berdasarkan Gambar 3.6 yang menyajikan Distribusi Domisili Pasien, ditemukan bahwa Jakarta merupakan wilayah dengan konsentrasi pasien tertinggi yang sangat dominan dibandingkan wilayah lainnya. Dominasi ini memberikan landasan logis yang kuat bagi pemilihan data curah hujan Jakarta sebagai fitur eksogen utama dalam model. Penggunaan data cuaca dari wilayah dengan populasi sampel terbesar memastikan bahwa sinyal eksternal yang dimasukkan ke dalam model memiliki probabilitas keterpaparan (exposure) yang tinggi terhadap mayoritas subjek klaim.

Setelah menetapkan relevansi geografis pada tahap sebelumnya, dilakukan analisis terhadap dampak curah hujan Jakarta terhadap volatilitas klaim. Hasil pengujian statistik menunjukkan nilai korelasi Pearson sebesar 0,1494 (p-value: 0,5952) dan korelasi Spearman sebesar 0,3633 (p-value: 0,1832). Meskipun korelasi linier terlihat sangat lemah, terdapat anomali pada korelasi peringkat yang memberikan wawasan lebih dalam mengenai karakteristik data.




Gambar 3.7 Perbandingan Curah Hujan Maksimal Jkt Dengan Frekuensi Klaim
Tingginya nilai korelasi Spearman (0,3633) dibandingkan Pearson (0,1494) membuktikan adanya hubungan non-linier yang cukup terdeteksi. Dalam konteks asuransi kesehatan di Jakarta, hal ini menunjukkan bahwa curah hujan memengaruhi klaim bukan melalui peningkatan yang stabil, melainkan kemungkinan melalui efek ambang batas (threshold). Sebagai contoh, klaim baru akan melonjak secara drastis hanya pada saat intensitas hujan mencapai titik ekstrem yang memicu genangan atau penurunan kualitas sanitasi lingkungan. Keunggulan Spearman ini menjadi justifikasi utama mengapa algoritma non-linier seperti CatBoost tetap mampu memanfaatkan fitur ini untuk meningkatkan akurasi prediksi meskipun korelasi liniernya rendah.




Gambar 3.8 Regression Line Time Index Square
Penggunaan fitur Time_Index_Squared bertujuan untuk menangkap pola pergerakan data yang tidak bersifat linier seiring berjalannya waktu. Berdasarkan Gambar 3.8 terlihat bahwa garis regresi menunjukkan adanya lengkungan atau percepatan pada periode tertentu. Penambahan fitur polinomial derajat dua ini memberikan dimensi tambahan bagi model untuk memahami apakah pertumbuhan atau penurunan klaim terjadi secara konstan atau mengalami eskalasi.

Garis lengkung pada Gambar 3.8 membuktikan bahwa model tidak dipaksa untuk mengikuti garis lurus yang kaku, sehingga mampu meminimalisir kesalahan prediksi (error) pada titik-titik waktu di mana terjadi lonjakan yang bersifat

eksponensial. Hal ini memberikan keunggulan dalam hal fleksibilitas model untuk melakukan ekstrapolasi tren masa depan secara lebih akurat.




Gambar 3.9 Visualisasi Simetri Month Cos
Berdasarkan Tabel Ringkasan Statistik dan hasil perbandingan pasangan bulan simetris, dilakukan evaluasi terhadap efektivitas fitur month_cos. Analisis ini didukung oleh Gambar 3.9 yang menunjukkan visualisasi simetri fungsi kosinus dan Gambar 3.10 yang menampilkan grafik selisih persentase antar-pasangan bulan. Secara keseluruhan, data menunjukkan tingkat keserupaan yang tinggi pada mayoritas pasangan bulan, yang memvalidasi penggunaan fitur siklikal ini.




Gambar 3.10 Validasi Keserupaan Claim Severity By Month Cos
Data menunjukkan bahwa fitur month_cos berhasil mengelompokkan periode dengan karakteristik beban finansial yang serupa. Pasangan bulan 3 dan 9 menunjukkan selisih terkecil, yaitu 1,82 persen, diikuti oleh pasangan 5 dan 7 sebesar 2,66 persen. Angka selisih di bawah 5 persen pada tiga dari lima pasangan bulan membuktikan bahwa asumsi simetri pada fitur kosinus memiliki landasan empiris yang kuat pada dataset klaim ini.

4) PENGARUH FITUR ENDOGEN




Gambar 3.11 Grafik Ccf Lag Predictor Total Claim Terhadap Claim Frequency

Pada Gambar 3.11 terlihat bahwa korelasi antara data historis total claim 2 bulan dan 4 bulan sebelumnya memberikan korelasi yang tinggi terhadap Claim Frequency. Dibuktikan dengan Cross-Correlation Function (CCF) yang menunjukkan adanya batang korelasi yang lebih tinggi dibanding bulan lainnya. Hubungan ini melatarbelakangi penggunaan fitur lag dari variabel total klaim dalam arsitektur model untuk meningkatkan akurasi prediksi pada variabel Claim Frequency.



Gambar 3.12 Grafik Ccf Lag Predictor Total Claim Terhadap Claim Severity

Pada Gambar 3.12 terlihat bahwa korelasi antara data historis *Claim Frequency* memberikan pengaruh yang signifikan terhadap tingkat *Claim Severity*. Hal ini dibuktikan melalui *Cross-Correlation Function* (CCF) yang menunjukkan adanya batang korelasi yang cukup tinggi pada periode data historis 2 bulan dan 4 bulan yang lalu jika dibandingkan dengan bulan lainnya. Hubungan temporal ini melatarbelakangi penggunaan fitur *lag* dari variabel frekuensi klaim dalam arsitektur model untuk meningkatkan akurasi prediksi pada variabel *Claim Severity*.



Gambar 3.13 Grafik Ccf Lag Predictor Total Claim Terhadap Claim Severity

Gambar 3.13 menunjukkan bahwa riwayat data Total Claim memiliki pengaruh yang signifikan terhadap fluktuasi tingkat Claim Severity di masa mendatang. Analisis melalui Cross-Correlation Function (CCF) membuktikan adanya keterkaitan temporal yang kuat pada periode 2 bulan sebelumnya, di mana batang korelasi menunjukkan nilai yang jauh lebih tinggi dibandingkan dengan periode waktu lainnya. Temuan ini menjadi dasar bagi tim peneliti dalam memilih fitur lag dari variabel total klaim untuk memperkuat arsitektur model, sehingga akurasi prediksi pada variabel Claim Severity dapat ditingkatkan secara optimal.

B. MACHINE LEARNING TRAINING

1) *HASIL FEATURE SELECTION EVOLUTIONARY COMPUTATION*

Melalui algoritma Evolutionary Computation dengan Model CatBoost didapatkan kombinasi fitur spesifik yang memberikan kontribusi maksimal terhadap akurasi model. Fitur-fitur yang terpilih mencakup variabel temporal, historis, dan eksternal seperti curah hujan yang memiliki korelasi kuat terhadap risiko klaim. Daftar fitur optimal hasil seleksi EC disajikan dalam tabel berikut:

Target Variabel	Fitur Terpilih (Selected Features)
Claim_Frequency	Lag_4_Total, Working_Days, RM_2_Freq, Time_Index_Squared
Claim_Severity	Max_Daily_Rainfall_Jkt, Lag_2_Freq, month_cos, Lag_2_Total, Lag_4_Freq

Implementasi seleksi fitur ini memberikan hasil performa yang signifikan pada validasi rekursif model CatBoost.

2) HASIL HYPERPARAMETER TUNING EVOLUTIONARY COMPUTATION

Algoritma evolusi dijalankan pada tiga kerangka kerja model yang berbeda, yaitu CatBoost, LightGBM (LGBM), dan XGBoost (XGB). Berdasarkan hasil simulasi selama 15 hingga 20 generasi dengan 100 populasi, ditemukan parameter optimal untuk variabel Claim Frequency dan Claim Severity sebagai berikut:

Model	Target	Iterasi / Estimator	Kedalaman (Depth)	Learning Rate	Regulasi (L2/λ)
CatBoost	<i>Frequency</i>	200	3	0,08	5
	<i>Severity</i>	300	4	0,08	15
LightGBM	<i>Frequency</i>	150	6	0,08	5
	<i>Severity</i>	300	3	0,1	3
XGBoost	<i>Frequency</i>	50	3	0,05	1
	<i>Severity</i>	250	4	0,1	1

3) HASIL TRAINING


Setelah melalui fase optimasi hiperparameter menggunakan algoritma evolusi selama 15 generasi, diperoleh hasil performa dari tiga kerangka kerja model yang berbeda. Evaluasi ini dilakukan dengan membandingkan nilai galat pada validasi internal dan skor pada papan peringkat publik untuk menentukan model yang paling konsisten. Metrik yang digunakan dalam perbandingan ini adalah *Mean Absolute Percentage Error* (MAPE) dalam satuan persentase.

Algoritma	CV Score (Lokal)	Public Score (LB)
CatBoost	3,05%	1,06%
XGBoost	3,88%	3,24%
LightGBM	4,34%	2,47%

CatBoost terpilih sebagai model terbaik karena mencatatkan nilai galat terendah pada metrik CV maupun Public Score secara konsisten. Capaian skor publik sebesar 1,0582% membuktikan ketajaman algoritma ini dalam memproyeksi tren klaim pada periode target secara presisi. Performa unggul tersebut didukung oleh konfigurasi hiperparameter yang


mampu menjaga stabilitas prediksi selama proses peramalan rekursif dilakukan.

XGBoost menunjukkan tingkat stabilitas generalisasi paling konsisten dengan deviasi terkecil antara validasi lokal dan skor publik. Sementara itu, LightGBM berhasil mencatatkan skor publik yang lebih kompetitif dibandingkan XGBoost meskipun memiliki nilai galat CV tertinggi di angka 4,34%. Berdasarkan seluruh parameter evaluasi tersebut, CatBoost tetap ditetapkan sebagai model final untuk menjamin akurasi maksimal dalam estimasi nilai klaim.



Gambar 3.14 Feature Importance Untuk Claim Freq


Analisis Gambar 3.14 menunjukkan bahwa variabel Lag_4_Total dan RM_2_Freq merupakan faktor paling dominan dalam menentukan proyeksi frekuensi klaim bulanan. Kontribusi tinggi dari kedua fitur ini mengonfirmasi bahwa tren historis serta rata-rata bergerak periode sebelumnya menjadi dasar utama algoritma dalam menangkap pola volume klaim secara akurat. Hal ini membuktikan bahwa stabilitas prediksi frekuensi sangat bergantung pada kesinambungan data perilaku klaim di masa lalu.



Gambar 3.15 Feature Importance Untuk Claim Severity


Dari Gambar 3.15, fitur Lag_2_Freq dan Max_Daily_Rainfall_Jkt diidentifikasi sebagai prediktor utama yang memengaruhi tingkat keparahan klaim. Kehadiran variabel curah hujan ekstrem sebagai faktor signifikan menegaskan adanya korelasi kuat antara fenomena cuaca di wilayah Jakarta dengan besaran nilai kerugian finansial klaim.

C. HASIL PREDIKSI



Gambar 3.16 Grafik Yoy Hasil Prediksi Total Claim


Analisis terhadap Gambar 3.16 menunjukkan bahwa model memiliki stabilitas yang baik namun cenderung melakukan penghalusan pada fluktuasi ekstrem. Secara optimistis, model ini dikategorikan robust karena mampu menyelaraskan transisi data aktual ke prediksi tanpa diskontinuitas, serta berhasil mempertahankan pola musiman seperti puncak klaim di bulan Juli yang konsisten dengan tren tahun-tahun sebelumnya. Sebaliknya, dari sudut pandang pesimistis, garis proyeksi 2026 terlihat terlalu linear dibandingkan volatilitas tinggi pada awal 2024, yang mengindikasikan adanya risiko *underestimation* terhadap lonjakan klaim mendadak akibat penggunaan input cuaca rata-rata yang bersifat statis. Keterbatasan ini menunjukkan bahwa meskipun model sangat andal untuk estimasi biaya operasional rutin, perusahaan tetap memerlukan cadangan kontingensi tambahan untuk mengantisipasi kejadian luar biasa yang tidak sepenuhnya tertangkap oleh tren rata-rata historis tersebut.



Gambar 3.17 Grafik Yoy Hasil Prediksi Claim Frequency

Analisis terhadap Gambar 3.17, yang menyajikan analisis perbandingan Year-on-Year (YoY) frekuensi klaim dari tahun 2024 hingga 2026, menunjukkan bahwa model memiliki kemampuan proyeksi yang stabil namun cenderung melakukan penghalusan terhadap volatilitas historis. Secara optimistis, model ini dikategorikan robust karena mampu menyelaraskan transisi data aktual ke prediksi tanpa diskontinuitas, serta berhasil mempertahankan

pola musiman seperti puncak klaim di bulan Juli yang konsisten dengan tren tahun-tahun sebelumnya. Keberhasilan model dalam mempertahankan bentuk kurva musiman jangka panjang tanpa mengalami penyimpangan nilai yang ekstrem (drift) membuktikan generalisasi yang kuat. Sebaliknya, dari sudut pandang pesimistis, garis proyeksi 2026 terlihat terlalu linear dibandingkan volatilitas tinggi pada awal tahun 2024, yang mengindikasikan adanya risiko *underestimation* terhadap lonjakan klaim mendadak akibat penggunaan input cuaca rata-rata historis yang bersifat statis. Keterbatasan ini menunjukkan bahwa meskipun model sangat andal untuk estimasi frekuensi klaim rutin, perusahaan tetap memerlukan cadangan kontingensi tambahan untuk mengantisipasi kejadian luar biasa yang tidak sepenuhnya tertangkap oleh tren rata-rata historis tersebut.



Gambar 3.18 Grafik Yoy Hasil Prediksi Claim Severity

Analisis terhadap Gambar 3.18, yang menyajikan analisis perbandingan Year-on-Year (YoY) Severity Klaim dari tahun 2024 hingga 2026, menunjukkan bahwa model memiliki kemampuan proyeksi yang stabil namun cenderung melakukan penghalusan terhadap volatilitas historis jangka panjang. Secara optimistis, model ini dikategorikan robust karena mampu menyelaraskan transisi data aktual ke prediksi pada bulan Agustus 2025 tanpa diskontinuitas yang aneh. Garis proyeksi 2026 (merah) menunjukkan tren musiman di akhir tahun (Desember) yang konsisten dengan data historis 2024 dan 2025 yang juga menurun, yang berarti model menangkap sinyal musiman dasar di akhir tahun. Selain itu, proyeksi jangka panjang 2026 tidak mengalami drifting liar meskipun data historis 2024 sangat fluktuatif, menunjukkan kemampuan generalisasi yang kuat terhadap rentang nilai historis. Sebaliknya, dari sudut pandang pesimistis, keterbatasan utama model terlihat pada garis proyeksi 2026 yang terlalu linear dan datar dibandingkan

dengan volatilitas tinggi di masa aktual tahun 2024 dan 2025. Penghalusan ekstrem ini menunjukkan risiko *underestimation* terhadap lonjakan klaim ekstrem, yang kemungkinan besar disebabkan oleh penggunaan input eksogen cuaca rata-rata historis untuk tahun 2026, sehingga kehilangan sinyal cuaca ekstrem yang spesifik per tahun yang sebenarnya dapat memicu lonjakan keparahan klaim. Keterbatasan ini menunjukkan bahwa model sangat andal untuk estimasi biaya keparahan klaim rutin, namun perusahaan tetap memerlukan cadangan kontingensi tambahan untuk mengantisipasi kejadian luar biasa yang tidak sepenuhnya tertangkap oleh tren rata-rata historis tersebut.

IV. PENUTUPAN

A) KESIMPULAN DAN SARAN

Penelitian ini menyimpulkan bahwa akurasi proyeksi klaim asuransi kesehatan sangat bergantung pada integrasi faktor historis, seperti tren lag total klaim dan frekuensi, serta faktor eksogen berupa jumlah hari kerja dan intensitas curah hujan ekstrem melalui arsitektur dekomposisi frequency-severity. Model dioptimalkan secara sistematis melalui penanganan pencilaan dengan metode capping pada kuantil 0,97, seleksi fitur berbasis Evolutionary Computation untuk mengeliminasi noise, serta tuning parameter menggunakan algoritma genetika. Sinergi ini memungkinkan algoritma CatBoost menangkap hubungan non-linier yang kompleks dan menghasilkan proyeksi yang sangat stabil dengan nilai galat Public Score sebesar 1,06 persen, yang membuktikan keunggulan model dalam menjaga konsistensi tren musiman tahunan.

Meskipun model menunjukkan robustitas yang tinggi dan transisi data yang halus, terdapat kecenderungan penghalusan terhadap fluktuasi ekstrem sebagai dampak penggunaan input rata-rata historis untuk proyeksi jangka panjang. Sebagai saran, perusahaan direkomendasikan untuk tetap menyediakan cadangan kontingensi tambahan di atas nilai proyeksi guna memitigasi risiko lonjakan klaim mendadak atau kejadian luar biasa yang tidak tertangkap oleh tren rata-rata. Selain itu, diperlukan pemantauan berkala terhadap performa model dan pembaruan data eksogen secara aktual untuk menjaga sensitivitas prediksi terhadap perubahan dinamika

lingkungan serta memastikan ketahanan finansial perusahaan tetap terjaga secara optimal dalam menghadapi risiko masa depan.

B) REFERENSI

- [1] Buddiga, S. K. P. (2020). The Importance of Data Cleaning in Machine Learning: Best Practices and Techniques. *European Journal of Advances in Engineering and Technology*, 7(10), 70-73.
- [2] Lainer, A. D., & Wolfinger, R. D. (2022). Forecasting with gradient boosted trees: augmentation, tuning, and cross-validation strategies. *International Journal of Forecasting*, 38, 1426-1433.
- [3] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6620-6631.
- [4] Karmaker, S. (2025). *Feature Engineering in Time Series Forecasting*. Technische Universität Chemnitz.
- [5] Song, X., Zhang, Y., Zhang, W., He, C., Hu, Y., Wang, J., & Gong, D. (2024). Evolutionary computation for feature selection in classification: A comprehensive survey of solutions, applications and challenges. *Swarm and Evolutionary Computation*, 90, 101661.
- [6] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021.
- [7] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M5 accuracy competition: Results, findings and conclusions," *Int. J. Forecast.*, vol. 38, no. 4, pp. 1346-1364, 2022.
- [8] A. Zeng, M. Chen, L. Zhang, and Q. Wu, "Are transformers effective for time series forecasting?," in *Proc. AAAI Conf. Artif. Intell.*, vol. 37, no. 9, 2023, pp. 11121-11128.
- [9] M. V. Wüthrich and M. Merz, *Statistical Foundations of Actuarial Learning and its Applications*, Cham, Switzerland: Springer, 2023.
- [10] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.
- [11] Chen, T., & Guestrin, C. (2016, August). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794).